

Appendix E 拉格朗日乘子法 (Lagrange Multipliers)

拉格朗日乘子法用来寻找多元函数在一组约束下的驻点方法。

先考虑一个简单的情形，设 $\mathbf{x} = (x_1, x_2)^\top$ 为一个二维向量，要求在给定约束 $g(x_1, x_2) = 0$ 下求出 $f(x_1, x_2)$ 的驻点。

$$g(\mathbf{x}) = 0 \quad (\text{E.1})$$

一种简单的求解方法为，先通过 $g(x_1, x_2) = 0$ 将 x_2 表达为 x_1 的函数形式，即 $x_2 = h(x_1)$ 。通过对 $f(x_1, h(x_1))$ 求导求得 x_1^* ，随即得到 $x_2^* = h(x_1^*)$

上述方法的问题在于，有时候 $x_2 = h(x_1)$ 这个表达式很难构建出来，同时，这样的方法也破坏了变量之间的对称性。拉格朗日乘子法通过引入拉格朗日乘子 λ ，将等式约束融入到目标优化函数中。首先从几何角度来看，设 D 维向量 $\mathbf{x} = (x_1, x_2, \dots, x_D)$ 存在于一个 D 维空间中， $g(\mathbf{x}) = 0$ 表示该 D 维空间中的一个 $D-1$ 维曲面，对 \mathbf{x} 点附近做泰勒展开，可以得到

$$g(\mathbf{x} + \boldsymbol{\epsilon}) \simeq g(\mathbf{x}) + \boldsymbol{\epsilon}^\top \nabla g(\mathbf{x}) \quad (\text{E.2})$$

设 $\mathbf{x} + \boldsymbol{\epsilon}$ 为 $g(\mathbf{x}) = 0$ 曲面上的点，则 $g(\mathbf{x} + \boldsymbol{\epsilon}) = g(\mathbf{x}) = 0$ ，可以得到 $\boldsymbol{\epsilon}^\top \nabla g(\mathbf{x}) \simeq 0$ ，故可以得到下面的结论

- 曲面 $g(\mathbf{x}) = 0$ 在 \mathbf{x}_0 处的法向量为 $\nabla_{\mathbf{x}} g(\mathbf{x}_0)$
- 在寻找最优点 \mathbf{x}^* 时，该点的梯度方向 $\nabla_{\mathbf{x}} f(\mathbf{x}^*)$ 一定也正交于曲面，即存在一个非零值 λ 满足

$$\nabla f(\mathbf{x}^*) + \lambda \nabla g(\mathbf{x}^*) = 0 \quad (\text{E.3})$$

这里的 λ 就是**拉格朗日乘子 (Lagrange multiplier)**。这是显然的，因为如果 $\nabla_{\mathbf{x}} f(\mathbf{x}^*)$ 不垂直于曲面的话，可以通过沿着曲面与梯度相反的方向找到一个 \mathbf{x}_1^* ，使得 $f(\mathbf{x}_1^*) > f(\mathbf{x}^*)$ ，通过沿着曲面与梯度相反的方向找到一个 \mathbf{x}_2^* ，使得 $f(\mathbf{x}_2^*) > f(\mathbf{x}^*)$ 。

根据上述结论，我们引入拉格朗日表达式

$$L(\mathbf{x}, \lambda) \equiv f(\mathbf{x}) + \lambda g(\mathbf{x}) \quad (\text{E.4})$$

显然，(E.3)可以表示为 $\nabla_{\mathbf{x}} L(\mathbf{x}, \lambda) = 0$ ，而约束条件(E.1)可以表示为 $\frac{\partial L(\mathbf{x}, \lambda)}{\partial \lambda} = 0$

所以，带有(E.1)约束条件的极值问题转化为(E.5)的方程

$$\nabla_{\mathbf{x}, \lambda} L(\mathbf{x}, \lambda) = 0 \quad (\text{E.5})$$

考虑不等式约束 $g(\mathbf{x}) \geq 0$ ，寻找满足约束的 $f(\mathbf{x})$ 的最大值，考虑以下两种情况

- $g(\mathbf{x}) > 0$ ，此时约束不起作用 (**inactive**)，直接通过 $\nabla_{\mathbf{x}} f(\mathbf{x}) = 0$ 来求解最优点，对应于 $\lambda = 0$ 时拉格朗日函数优化，即 $\nabla_{\mathbf{x}} L(\mathbf{x}, \lambda = 0) = 0$
- $g(\mathbf{x}) = 0$ ，约束起到作用，等价于上面讨论的等式约束，值得注意的是，在最优点 \mathbf{x}^* 处， $\nabla_{\mathbf{x}} g(\mathbf{x}^*)$ 方向必须与 $\nabla_{\mathbf{x}} f(\mathbf{x}^*)$ 的方向必须相反，即 $\lambda > 0$ 。因为当方向相同时，只需将 \mathbf{x}^* 沿着 $\nabla_{\mathbf{x}} f(\mathbf{x}^*) = -\lambda \nabla_{\mathbf{x}} g(\mathbf{x}^*)$ 的方向移动，设新的点为 $\mathbf{x}^* + \boldsymbol{\epsilon}$ ，因为 $\lambda < 0$ ，新的点依然满足约束 $g(\mathbf{x} + \boldsymbol{\epsilon}) > g(\mathbf{x}) \geq 0$ ，而此时由于沿着 $f(\mathbf{x}^*)$ 的梯度方向移动，所以 $f(\mathbf{x} + \boldsymbol{\epsilon}) > f(\mathbf{x})$ ，即可以找到一个更优点来更新 \mathbf{x}^* 。

综合上述两个情况，在约束 $g(\mathbf{x}) \geq 0$ 下对 $f(\mathbf{x})$ 进行优化，可以转化成在如下条件下的拉格朗日函数(E.4)的优化问题

$$\begin{aligned} g(\mathbf{x}) &\geq 0 \\ \lambda &\geq 0 \\ \lambda g(\mathbf{x}) &= 0 \end{aligned} \tag{E.6}$$

这些条件被称为**KKT(Karush-Kuhn-Tucker)**条件。

上述方法可以推广到多个含等式和不等式的约束问题上，设我们希望最大化 $f(\mathbf{x})$ ，其中包含 J 个等式约束 $\{g_j(\mathbf{x}) = 0\}_{j=1}^J$ 和 K 个不等式约束 $\{h_k(\mathbf{x}) \geq 0\}_{k=1}^K$ ，按照上述方法分别引入 J 个和 K 个拉格朗日乘子 $\{\lambda_j\}_{j=1}^J, \{\mu_k\}_{k=1}^K$ ，优化的拉格朗日函数为

$$L(\mathbf{x}, \{\lambda_j\}_{j=1}^J, \{\mu_k\}_{k=1}^K) = f(\mathbf{x}) + \sum_{j=1}^J \lambda_j g_j(\mathbf{x}) + \sum_{k=1}^K \mu_k h_k(\mathbf{x}) \tag{E.7}$$

其中引入的KKT条件($k = 1, \dots, K$)为

$$\begin{aligned} h_k(\mathbf{x}) &\geq 0 \\ \mu_k &\geq 0 \\ \mu_k h_k(\mathbf{x}) &= 0 \end{aligned} \tag{E.8}$$